Epileptic Seizure Recognition from EEG Signals Using Classical Machine Learning

A Study on the SIENA Scalp EEG

Yanis AMARA

ESIEE Paris

yanis.amara@edu.esiee.fr

April 13, 2026

Abstract

Les crises d'épilepsie affectent environ 50 million de personnes dans le monde, faisant de leur détection sur des signaux EEG un challenge clinique critique. Dans ce travail, nous allons présenter une méthode inspirée du traitement du signal et du machine learning pour la reconnaissance de crises appliquée au dataset SIENA Scalp EEG. Notre approche combine l'extraction de features temporelles, fréquentielles et de connectivité.

Mots-clés : prédiction de crises épileptiques, EEG, SIENA Scalp EEG, MAACD, PLI, wPLI, LightGBM, porte OR.

Contents

1 Introduction **3**

2 Travaux Connexes **3**

3 Jeu de Données **3**
3.1 Base de données SIENA Scalp EEG . . . 3
3.2 Analyse exploratoire . . . 4
3.3 Sélection des sujets . . . 4

4 Prétraitement et Extraction de Features **5**
4.1 Prétraitement . . . 5
4.2 Extraction de Features . . . 5
4.2.1 Features fréquentielles . . . 5
4.2.2 Features temporelles . . . 5
4.2.3 Connectivité – PLI et wPLI . . . 6
4.2.4 MAACD . . . 6
4.3 Importance des features . . . 6

5 Protocole Expérimental **7**
5.1 Étiquetage des fenêtres . . . 7
5.2 Statistiques . . . 8
5.3 Validation croisée LOSO . . . 8
5.4 Métriques . . . 8

6 Pipelines et Classifieurs **8**
6.1 Baseline – ThAlgo . . . 9
6.2 Choix des 4 pipelines . . . 10
6.2.1 P1 — LightGBM: Full Feature Set (LOSO) . . . 10
6.2.2 P2 — LightGBM: No Connectivity Features . . . 11
6.2.3 P3 — Fused LightGBM + MAACD Score . . . 11
6.2.4 P4 — OR-Gate: LightGBM ∪ Focal MAACD (Proposée) . . . 11

7 Experiments and Results **12**
7.1 Baseline: ThAlgo Results . . . 12
7.2 P1 et P2: L'impact des features de connectivité . . . 13
7.3 P3: Fused Pipeline Results . . . 14
7.4 P4: OR-Gate Results (Méthode proposée) . . . 16
7.5 Cross-Pipeline Comparison . . . 17

8 Discussion **18**

9 Conclusion **19**

1. Introduction

L'épilepsie est l'un des troubles neurologiques les plus répandus, il est caractérisé par de récurrentes crises causées par une activité électrique anormale du cerveau [1].

L'électroencéphalogramme (EEG) reste l'outil clinique majoritairement utilisé pour la visualisation de ces crises. Cependant, l'interprétation manuelle est chronophage et requiert l'expertise de spécialistes confirmés. Les systèmes de détection automatiques peuvent assister des cliniciens en leur fournissant en temps réel des alertes prévenant l'apparition des crises et réduisant le temps de diagnostic.

Les approches classiques de machine learning appliquées à ce cas incluent notamment les Random Forests qui ont montrées d'excellentes performances sur la classification d'EEG tout en conservant une bonne interprétabilité, alors critique dans un enjeu clinique [5].

Motivation. Le défi principal est le fort déséquilibre des classes : les enregistrements EEG contiennent plusieurs heures d'activité interictale pour quelques minutes de crise. Les signatures cérébrales sont également très spécifiques à chaque patient, rendant la généralisation entre sujets particulièrement difficile.

2. Travaux Connexes

Approches classiques basées sur les features. Shoeb et Guttag [3] ont proposé un classifieur SVM patient-spécifique utilisant des features multi-canaux temps-fréquence, atteignant une haute sensibilité sur des EEG pédiatriques. Detti et al. [9] ont introduit sur le jeu de données SIENA Scalp EEG une approche basée sur la synchronie de phase (PLI/wPLI) transformée par un opérateur MAACD inspiré de l'analyse financière.

Méthodes ensemblistes. Alotaiby et al. [5] ont montré que la sélection de canaux combinée à des classifieurs par arbres réduit la dimensionnalité tout en maintenant de bonnes performances. LightGBM et XGBoost ont depuis démontré une supériorité sur les données biomédicales tabulaires grâce à leur gestion native du déséquilibre de classes.

3. Jeu de Données

3.1. Base de données SIENA Scalp EEG

Collectée à l'Université de Sienne, Italie [4, 9], la base contient les EEG de **14 patients atteints d'épilepsie focale** (9 hommes, 5 femmes, 20–71 ans), acquis à **512 Hz** avec le système 10–20, jusqu'à **32 canaux**. Elle contient **47 crises** sur environ **128 heures** d'enregistrement. Les horodatages ont été annotés manuellement par des neurologues, représentant une source d'incertitude non négligeable.

Table 1: Résumé des sujets de la base SIENA Scalp EEG.

Patient	**Sexe**	**Crises**	**Utilisé**
PN00	M	5	Oui
PN01	F	2	Oui
PN03	M	2	Oui
PN05	M	3	Oui
PN06	F	2	Oui
PN07	M	1	Non (1 crise)
PN09	M	3	Oui
PN10	F	10	Oui
PN11	M	1	Non (1 crise)
PN12	M	3	Oui
PN13	M	3	Oui
PN14	F	4	Oui
PN16	M	2	Oui
PN17	F	2	Oui
Total	–	**47**	**12 patients, 43 crises**

3.2. Analyse exploratoire

Déséquilibre des classes. La figure 1 illustre la proportion de fenêtres péri-ictales par patient (ratio moyen ≈1:9). Ce déséquilibre détermine les métriques d'évaluation et la stratégie de pondération.

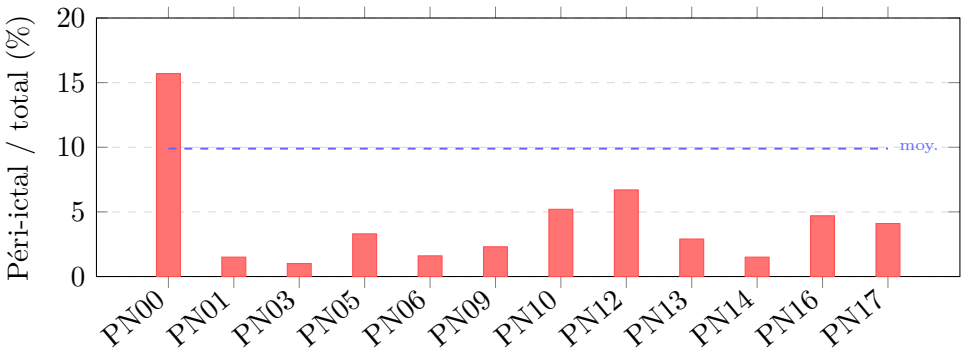

Figure 1: Proportion de fenêtres péri-ictales par patient. Ligne bleue : moyenne (9.9%).

3.3. Sélection des sujets

Les patients avec moins de deux épisodes de crises (PN07, PN11) sont exclus, conduisant à **12 patients** et **43 crises**. La validation croisée LOSO patient-spécifique est adoptée plutôt que LOPO, les ondes cérébrales étant hautement spécifiques à chaque individu.

4. Prétraitement et Extraction de Features

4.1. Prétraitement

Les EEG ont été filtrés (0.5–40 Hz, Butterworth) puis rééchantillonnés à **128 Hz**. Le théorème de Nyquist ($F_N = 64$ Hz) garantit l'absence de repliement pour les bandes utilisées (0.5–40 Hz). Les signaux sont segmentés en fenêtres de **6 s** avec un pas de **1 s** (5 s de recouvrement), soit 5× plus de fenêtres que Detti et al. Le recouvrement élevé (≈83% de similarité) est maîtrisé par le split LOSO au niveau des épisodes.

4.2. Extraction de Features

Pour chaque fenêtre, 18 features par canal sont calculées, plus les connectivités PLI/wPLI pour toutes les $N_f = N_c(N_c - 1)/2$ paires et leur valeurs de MAACD respectives.

Table 2: Dimensions du vecteur de features.

Patients	**Canaux**	**Temp.**	**Fréq.**	**Connect.**	**MAACD**	**Total**
PN00, PN01	29	203	319	812	812	2 146
PN03–PN13	28	196	308	756	756	2 016
PN14, PN16, PN17	27	189	297	702	702	1 890

4.2.1 Features fréquentielles

La Power Spectral Density (PSD) a été estimée sur chaque fenêtre en utilisant la méthode de Welch avec une fenêtre de Hann de 256 échantillons. La bande power B_k a été calculée par intégration numérique sur les 5 bandes fréquences types des EEGs

$$B_k = \int_{f_k^{\text{low}}}^{f_k^{\text{high}}} S(f)\,\mathrm{d}f, \qquad k \in \{\delta,\, \theta,\, \alpha,\, \beta,\, \gamma\} \tag{1}$$

avec les limites de bande suivantes δ: 0.5–4 Hz, θ: 4–8 Hz, α: 8–13 Hz, β: 13–30 Hz, γ: 30–40 Hz.

La Relative Band Power (RBP) a été définie comme:

$$\mathrm{RBP}_k = \frac{B_k}{\sum_k B_k + \varepsilon} \tag{2}$$

où $\varepsilon = 10^{-12}$ empêche la division par zero. Cela nous apporte 10 features par canal (5 absolues + 5 relatives).

4.2.2 Features temporelles

Hjorth [6].

$$\text{Act.} = \mathrm{Var}(x), \quad \text{Mob.} = \sqrt{\frac{\mathrm{Var}(x')}{\mathrm{Var}(x) + \varepsilon}}, \quad \text{Comp.} = \frac{\sqrt{\mathrm{Var}(x'')/(\mathrm{Var}(x') + \varepsilon)}}{\text{Mob.} + \varepsilon} \tag{3}$$

Entropie de permutation ($m = 3$). $H_{\text{perm}} = -\sum_\pi p(\pi) \log p(\pi)$

Dimension fractale Higuchi (HFD) [7]. Estime l'autosimilarité du signal – sensible aux transitions préictales.

Moyenne et écart-type. $\mu = \frac{1}{N}\sum x[n], \quad \sigma = \sqrt{\frac{1}{N}\sum (x[n]-\mu)^2}$

4.2.3 Connectivité – PLI et wPLI

Le pipeline est appliqué au signal *continu* (jusqu'à 1 heure) pour éviter les effets de bord du filtrage : (1) filtre passe-bande alpha (Butterworth 4e ordre, 8–13 Hz, `filtfilt`), (2) différentiation, (3) transformée de Hilbert.

$$\text{PLI}_{ij}[w] = \left| \frac{1}{W-1} \sum_t \text{sgn}(\sin(\phi_i[t] - \phi_j[t])) \right| \tag{4}$$

$$\text{wPLI}_{ij}[w] = \frac{|\mathbb{E}[\text{Im}(\tilde{x}_i \tilde{x}_j^*)]|}{\mathbb{E}[|\,\text{Im}(\tilde{x}_i \tilde{x}_j^*)|] + \varepsilon} \quad [8] \tag{5}$$

4.2.4 MAACD

$$\text{MAACD}[t] = \text{EMA}(\text{PLI}[t], w{=}7) - \min_{s \in [t-26, t]} \text{EMA}(\text{PLI}[s], w{=}7) \tag{6}$$

4.3. Importance des features

Trois critères normalisés sont combinés en un score unique : MI, AUC univariée, gain LightGBM ($n_{\text{est}} = 400$).

$$\text{Score}_i = \frac{1}{3}(\tilde{\text{MI}}_i + \tilde{\text{AUC}}_i + \tilde{\text{LGB}}_i) \tag{7}$$

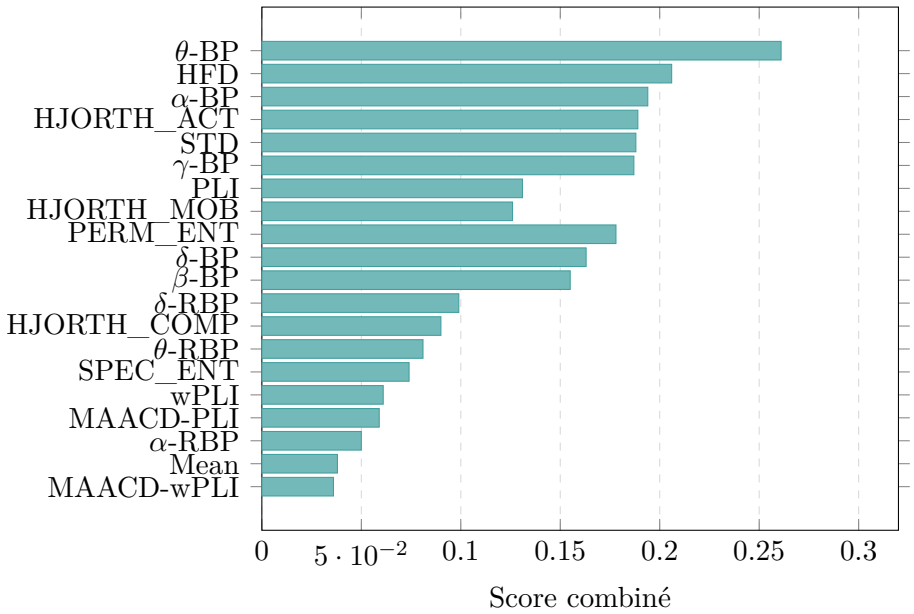

Figure 2: Score d'importance combiné par famille de features. Notons que les features de connectivité (PLI, wPLI, MAACD) du classement.

Table 3: Score moyen par famille ($N = 146\,747$ fenêtres).

Famille	**Score**
θ BP	0.261
HFD	0.206
α BP	0.194
Hjorth act.	0.189
STD	0.188
γ BP	0.187
Perm. entr.	0.178
δ BP	0.163
β BP	0.155
PLI	0.131
Hjorth mob.	0.126
γ RBP	0.117
β RBP	0.107
δ RBP	0.099
Hjorth comp.	0.090
θ RBP	0.081
Spec. entr.	0.074
wPLI	0.061
MAACD-PLI	0.059
α RBP	0.050
Mean	0.038
MAACD-wPLI	0.036

5. Protocole Expérimental

5.1. Étiquetage des fenêtres

- **Ictale** (label = 1) : dans l'intervalle annoté par le neurologue.
- **Pré-ictale** (label = 2) : dans les 5 min avant l'onset [9].
- **Interictale** (label = 0) : reste, excluant 1000 s post-ictal.

Classes positives et négatives : ictale+pré-ictale vs. interictale. Maximum 3600 s interictales retenues avant chaque crise. Ainsi bien qu'il y ai 3 labels différents, nous tenterons de résoudre au cours de cette étude un problème de **classification binaire** (Y = 1/2 ou 0) Nous gardons dans le dataset les trois labels pour d'autres études d'approfondissement avec une distinction précise des phases ictales et pré-ictales.

5.2. Statistiques

Table 4: Fenêtres retenues par patient.

Patient	Crises	Interict.	Péri-ict.	Total
PN00	5	9 831	1 825	5 977
PN01	2	47 759	728	7 928
PN03	2	86 248	844	8 044
PN05	3	20 978	709	11 182
PN06	2	42 706	686	7 886
PN09	3	24 033	573	11 373
PN10	10	63 948	3 359	32 955
PN12	3	20 432	1 490	10 290
PN13	3	30 231	913	11 713
PN14	4	72 451	1 104	15 504
PN16	2	16 712	825	8 025
PN17	2	17 666	753	7 953
Total	**43**	**132 221**	**14 526**	**146 747**

5.3. Validation croisée LOSO

Par patient, un épisode de crise est conservé comme fold de test, le reste servant à l'entraînement. Normalisation (`StandardScaler`) et calibration des seuils recalculées à chaque fold (aucun data leakage).

5.4. Métriques

Étant donné le déséquilibre ≈9:1, l'accent est mis sur la **sensibilité** et le **FA/h** :

$$\text{Sens} = \frac{TP}{TP + FN}, \quad \text{FA/h} = \frac{\text{fausses alarmes}}{\text{h inter-ictales}}, \quad \text{AUC} = \int_0^1 \text{TPR}(\text{FPR}^{-1}(t))\,\mathrm{d}t \tag{8}$$

Cible clinique [12] : Sens > 0.70 et FA/h < 0.15.

6. Pipelines et Classifieurs

Cinq pipelines évaluées sous protocole LOSO. Toutes partagent :

1. **vote majoritaire sur 10 fenêtres**: la majorité des 10 dernières fenêtres doivent être positives.
2. **6 fenêtres consécutives**: alarme déclenchée si au moins 6 fenêtres consécutives sont classées positives
3. **période réfractaire de 10 min**: plus de classification pendant 10 min après le déclenchement d'une alarme.

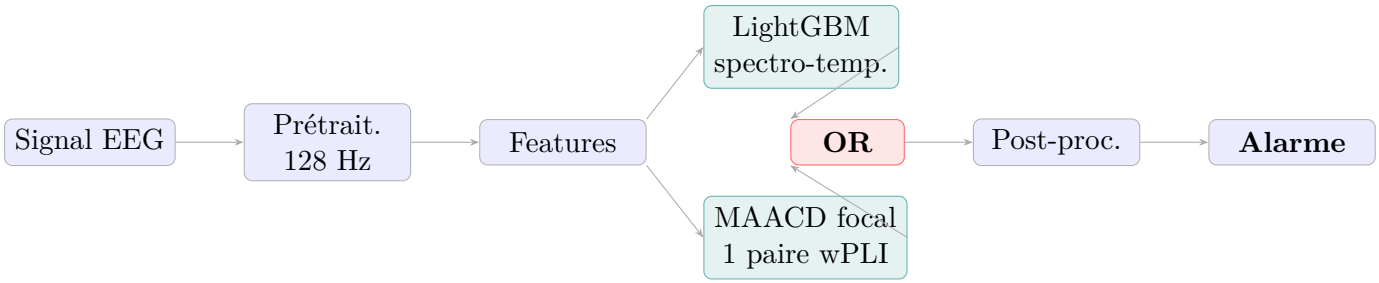

Figure 3: Architecture de la pipeline OR-Gate (P4).

Table 5: Résumé des cinq pipelines.

ID	Nom	Features	Classifieur
Baseline	ThAlgo	MAACD paires PLI+wPLI (702–812)	Règles
P1	LGBM-All	Toutes (1 900–2 200)	LightGBM
P2	LGBM-NoPLI	Temp.+Spectr. (486–522)	LightGBM
P3	Fused	Toutes + scalaire MAACD	LGBM+α-mix
P4	**OR-Gate**	**Non-PLI + 1 paire wPLI**	**LGBM$\vee$MAACD**

6.1. Baseline – ThAlgo

L'algorithme ThAlgo nous servira de baseline, elle reproduit l'approche introduite par Detti et al. [9].
Cette méthode repose exclusivement sur les valeurs de MAACD des features de connectivité inter-canaux PLI et wPLI.

Pair selection. Pour chaque fold de train et chaque patient, la fonction ThAlgo sélectionne deux paires sur cette ensemble:

- S_1 (*signal pair*): La paire dont la valeur moyenne de MAACD montre la plus grande augmentation sur les fenêtres peri-ictales
- S_2 (*silence pair*): La paire dont la valeur de MAACD reste la plus basse sur les fenêtres inter-ictales.

Cette algorithme repose uniquement sur le déclenchement d'une alarme sur la base du dépassement ou non de deux seuils θ_1 et θ_2

La sélection des seuils θ_1 and θ_2 est calibré sur le jeu d'entraînement. La règle de déclenchement de l'alarme est la suivante:

$$\text{Alarm}[t] = 1 \iff \text{MAACD}_{S_1}[t] > \theta_1 \ \wedge \ \text{MAACD}_{S_2}[t] < \theta_2 \tag{9}$$

Autrement dit, une alarme est envisagée si et seulement si le MAACD de la *signal pair* est supérieur au seuil θ_1 et que le MAACD de la *silence pair* est inférieur au seuil θ_2. Cette méthode minimise le temps de calcul et se concentre sur l'efficacité en sélectionnant seulement deux features sur environ 800. Le fait d'utiliser deux seuils pour deux features permettrait de maximiser la séparation des classes.

La décision de déclencher une alarme ou non est alors conclue par la chaîne de post-processing évoquée plus haut et commune à toutes les pipelines

Tous les 12 patients ont sélectionné une paire wPLI pour S_1.

Table 6: Paires ThAlgo sélectionnées le plus souvent.

Patient	S_1	S_2
PN00	WPLI_CH11_CH24	WPLI_CH14_CH24
PN01	WPLI_CH1_CH22	WPLI_CH2_CH19
PN03	WPLI_CH3_CH12	PLI_CH26_CH29
PN05	WPLI_CH15_CH27	PLI_CH19_CH26
PN06	WPLI_CH19_CH22	PLI_CH4_CH18
PN09	WPLI_CH8_CH16	PLI_CH5_CH19
PN10	WPLI_CH1_CH7	PLI_CH13_CH28
PN12	WPLI_CH23_CH29	PLI_CH23_CH24
PN13	WPLI_CH23_CH24	PLI_CH10_CH15
PN14	WPLI_CH21_CH23	PLI_CH1_CH5
PN16	WPLI_CH14_CH21	PLI_CH1_CH28
PN17	WPLI_CH11_CH12	PLI_CH9_CH14

6.2. Choix des 4 pipelines

En étudiant d'autres études sur l'application du machine learning pour la détection des crises d'épilepsie, la classification par arbres de décision et Random Forests est revenue à de nombreuses reprises avec d'excellents résultats En effet, la quantité importante de features peu ou pas corrélées dans un contexte aussi imprévisible que celui de l'activité cérébrale, fait de ce problème non-linéaire, un cas d'application plus que justifié pour les arbres de décision.

Nous avons alors décidé d'utiliser la librairie scikit-learn LightGBM, proposant des modèles de random forest optimisés par gradient boosting.

Nous avons testé ce modèle dans différentes pipelines dans le but d'optimiser les résultats. Toutes les features ont été normalisées centrées réduites en utilisant une instance `StandardScaller` calibrée sur le jeu d'entraînement. Le déséquilibre des classes restant (avec un ratio d'environ 1:9 entre les périodes péri-ictales et inter-ictales) a été compensée à l'aide d'un apprentissage pondéré et sensible aux coûts.

6.2.1 P1 — LightGBM: Full Feature Set (LOSO)

La pipeline P1 entraîne un classifieur LightGBM de manière naïve sur la totalité des features soit un nombre total de features d'environ 1 900-2 100 en fonction du nombre de canaux.

Les hyperparamètres du modèle sont: $n_{\text{est}} = 600$, learning rate $\eta = 0.03$, max depth = 7, 31 leaves, subsample=0.8 et column_sample=0.8, avec $w^+ = N^-/N^+$ pour la correction du déséquilibre de classe. Un seuil de décision fixe de 0.55 a été appliqué.

6.2.2 P2 — LightGBM: No Connectivity Features

Dans la pipeline P2, nous avons voulu tester la contribution des features de connectivité PLI/wPLI/MAACD-PLI/MAACD-wPLI face au reste des features.
Pour cela, nous avons supprimé toutes les features de connectivité: PLI et wPLI + MAACD pour ne garder que les 18 familles de features temporelles et spectrales (486-522 features par patients). L'architecture LightGBM est identique à celle utilisée dans la P1. Cette fois ci, la valeur du seuil de décision est calibrée pour chaque fold sur les données d'entraînement pour minimiser le nombre de faux positifs (FA/h ≤ 1)

6.2.3 P3 — Fused LightGBM + MAACD Score

La pipeline P3 combine la probabilité sortie par la pipeline P1 avec un score MAACD dans une somme pondérée.

$$s_{\text{fused}}[w] = \alpha \cdot P_{\text{LGB}}[w] + (1 - \alpha) \cdot s_{\text{MAACD}}[w] \tag{10}$$

où $s_{\text{MAACD}}[w]$ est la moyenne sur tous les canaux des valeurs de MAACD-PLI et MAACD-wPLI normalisées sur $[0, 1]$ pour une fenêtre w.
Notons que le seuil de décision utilisé sur la branche LGB n'est plus fixe mais calibré sur $s_{\text{fused}}[w]$

$\alpha \in \{0.0, 0.1, \ldots, 1.0\}$ est un coefficient optimisé par grid-search sur les folds d'entraînement pour maximiser la sensibilité tout en visant un taux de faux-positifs FA/h ≤ 2. Encore une fois, l'alarme est déclenchée après lissage sur 10 fenêtres et $k = 6$ fenêtre positives consécutives.

6.2.4 P4 — OR-Gate: LightGBM $\cup$ Focal MAACD (Proposée)

La pipeline P4 est le système proposé. Elle découple les deux sources d'informations (spectrales et temporelles vs connectivité inter-canal) en deux branches indépendantes et les couplent avec une porte logique OR.

1er branche — LightGBM sans features de connectivité. Un classifieur LightGBM est entraîné sur le même set de 486-522 features que P2. Le seuil de décision est calibré pour chaque fold afin de viser un taux de faux positifs FA/h ≤ 1.

2nd branche — Focal MAACD sur une unique paire wPLI spécifique au patient
Une seule paire de canaux nous donnant une valeur de wPLI est sélectionnée par patient et par fold: la pair dont le signal MAACD montre la moyenne la plus élevée pendant les phases péri-ictales du set d'entraînement. Un seuil $\hat{\tau}$ est calibré sur les fenêtres inter-ictales pour avoir FA/h ≤ 1, et l'alarme est déclenchée quand k valeurs consécutives de MAACD dépassent $\hat{\tau}$. Ce paramètre k est testé sur {6, 7, 8, 10} et le seuil sur {0.6, 0.7, 0.8}.

Règle de fusion

$$\text{Alarm}[t] = \text{Alarm}_{\text{LGB}}[t] \ \vee \ \text{Alarm}_{\text{MAACD}}[t] \tag{11}$$

La branche 1 offre une spécificité élevée grâce à une discrimination multi-features, tandis que la branche 2 permet de détecter des crises dont la signature péri-ictales est plus

marquée par une modification focale de la connectivité que le modèle global LightGBM pourrait ne pas capter.

7. Experiments and Results

7.1. Baseline: ThAlgo Results

La Table 7 reporte les performances de la baseline ThAlgo considérant deux critères d'alarme différent: la métrique utilisée par Detti et al. [9] (déclenchement si au moins une fenêtre positive dans l'interval peri-ictale) et la métrique que nous utilisons (au moins 6 fenêtres positives consécutives requises)

Table 7: ThAlgo results under paper metric and alarm metric. AUC reported for ThAlgo alarm-metric variant.

	Paper metric			**Alarm metric (6 consec.)**		
Patient	**AUC**	**Sens**	**FA/h**	**AUC**	**Sens**	**FA/h**
PN00	0.531	1.000	438.96	0.531	0.900	5.76
PN01	0.470	1.000	581.74	0.470	1.000	5.22
PN03	0.530	1.000	388.96	0.530	1.000	5.22
PN05	0.500	1.000	364.17	0.500	0.333	4.70
PN06	0.514	1.000	475.83	0.514	0.333	6.26
PN09	0.543	0.667	335.27	0.543	0.333	5.04
PN10	0.492	1.000	539.08	0.492	0.940	5.72
PN12	0.495	1.000	524.21	0.495	0.667	5.63
PN13	0.524	1.000	479.22	0.524	0.667	5.74
PN14	0.545	1.000	361.17	0.545	1.000	4.93
PN16	0.489	1.000	437.69	0.489	1.000	4.72
PN17	0.525	1.000	393.65	0.525	1.000	4.96
Mean	**0.513**	**0.972**	**443.3**	**0.513**	**0.764**	**5.32**

Avec la métrique de Detti et al. [9], ThAlgo atteint une sensibilité preste parfaite ($\overline{\text{Sens}} = 0.972$ mais avec un taux de fausse alarme extrêmement élevé ($\overline{\text{FA/h}} = 443.3$), rendant cette version cliniquement inutilisable. En appliquant le filtre d'alarme à 6 fenêtres consécutives avec une période réfractaire de 10 min, nous réduisont ce taux FA/h à 5.32, au prix de la sensibilité descendant alors à 0.764.

Notons bien que le nombre de faux-positifs est artificiellement limité à 6-7 FA/h à cause de la période réfractaire de 10min après chaque alarme. C'est un point important, car bien que ce critère nous permettent de réduire drastiquement le nombre de faux-positifs, un taux $FA/h \approx 5 - 6$ indique un modèle trivial incapable de discriminer et qui classe tout dans la classe positive.

Cette Baseline présente une sensibilité cliniquement acceptable, mais un taux de faux-positifs toujours élevée. Notre objectif dans la suite sera de maximiser cette sensibilité tout en minimisant les faux-positifs, pour tendre vers un modèle au moins autant prédictif et plus discriminant.

7.2. P1 et P2: L'impact des features de connectivité

Table 8 compare LGBM-All (P1) et LGBM-NoPLI (P2), les deux avec une calibration de seuil pour viser FA/h ≤ 1

Table 8: Comparison of LGBM-All (P2) vs. LGBM-NoPLI (P3). Both use FA/h ≤ 1 threshold tuning.

	P2: LGBM-All			**P3: LGBM-NoPLI**		
Patient	**AUC**	**Sens**	**FA/h**	**AUC**	**Sens**	**FA/h**
PN00	0.827	0.700	2.61	0.835	0.700	2.61
PN01	0.638	0.000	0.78	0.637	0.500	0.78
PN03	0.874	0.500	0.00	0.871	0.000	0.00
PN05	0.749	0.000	0.00	0.708	0.000	0.00
PN06	0.454	0.000	0.39	0.478	0.500	0.78
PN09	0.745	0.000	0.00	0.747	0.000	0.00
PN10	0.562	0.700	4.38	0.598	0.900	4.14
PN12	0.610	0.833	1.78	0.585	0.833	2.08
PN13	0.648	0.000	1.30	0.657	0.000	2.35
PN14	0.643	0.250	1.57	0.591	0.250	1.96
PN16	0.844	1.000	1.17	0.865	1.000	1.57
PN17	0.554	0.500	1.57	0.549	0.500	1.96
Mean	**0.679**	**0.374**	**1.30**	**0.677**	**0.432**	**1.52**

Supprimer toutes les features PLI et wPLI ne dégrade pas les performances: LGBM-NoPLI obtient une moyenne de sensibilité de 0.432 contre 0.374 pour LGBM-All, avec une une valeur d'AUC de 0.677 contre 0.679 et un léger taux de fausse alarme supérieur (1.52 FA/h contre 1.30 FA/h). Ce résultat contre-intuitif nous apprend que les features de connectivité, malgré leur importance théorique, n'apportent pas de pouvoir discriminant supplémentaire que ce qui est capturé sur le signal par les features temporelles et spectrales seules sur ce modèle LightGBM.

Pour pousser l'évaluation des performances de ces features de connectivité, nous avons décidé de voir les résultats que nous pourrions obtenir en entraînant un modèle sur ces features seules.

Nous avons alors entraîné un classifieur LightGBM sur les mêmes features MAACD avec les mêmes hyperparamètres présentés pour P1.

Nous observons que le modèle a échoué complètement: Il a prédit une classe négative pour toutes les fenêtres de test pour 11 patients sur 12 (Sens = = 0.000, FA/h = 0.09, confirmant que les features MAACD de connectivité seules, bien que capturant les dynamiques péri-ictales visuellement, ne procurent pas suffisament de pouvoir discriminant pour un classifieur comme LightGBM.

Cela est en accord avec le faible score pour les features PLI et wPLI observé dans l'analyse des features.

Les pipelines P1 et P2 nous apprennent alors que les features de connectivité :

1. sont très peu discriminantes dans un classifieur LightGBM
2. ajoute plus de bruit qu'autre chose quand ajoutées aux features spectro-temporelles.

Dans la suite, nous continueront de les évaluer comme dans la baseline avec un système de *threshold*

7.3. P3: Fused Pipeline Results

La Table 10 reporte les performances des deux branches de la pipeline P3

Table 9: Résultats des deux branches de P3.

	LightGBM arm			**MAACD arm**		
Pat.	**AUC**	**Sens**	**FA/h**	**AUC**	**Sens**	**FA/h**
PN00	0.833	0.700	2.27	0.558	1.000	7.02
PN01	0.629	0.000	0.78	0.537	1.000	6.26
PN03	0.882	0.000	0.00	0.492	1.000	5.87
PN05	0.746	0.000	0.00	0.622	1.000	5.74
PN06	0.466	0.500	0.39	0.506	1.000	5.87
PN09	0.759	0.000	0.00	0.597	0.667	6.09
PN10	0.589	0.100	1.83	0.519	0.900	6.18
PN12	0.598	0.500	1.47	0.493	1.000	5.63
PN13	0.658	0.000	1.30	0.534	1.000	5.74
PN14	0.614	0.250	1.57	0.606	1.000	5.87
PN16	0.857	1.000	1.17	0.515	1.000	5.34
PN17	0.532	0.500	1.17	0.554	1.000	6.26
Mn	**0.680**	**0.296**	**1.00**	**0.545**	**0.964**	**5.99**

La branche MAACD seule obtient un très haut score de sensibilité ($\overline{\text{Sens}} = 0.964$) mais un taux de fausse alarme de ($\overline{\text{FA/h}} = 5.99$).

Cette branche semble présenter à elle seule une meilleure sensiblité que la baseline, en opérant sur les PLI/wPLI moyennées plutôt que sur une sélection spécifique de deux paires. Cependant, en mettant en parallèle cette sensibilité quasi-parfaite avec le nombre de faux-positifs important, nous pouvons en conclure que cette amélioration relève essentiellement du bruit, où le modèle, alors pas du tout discriminant, prédit simplement tout le temps la classe positive.

La branche LGBM apporte elle une sensibilité bien plus faible $\overline{\text{Sens}} = 0.296$ avec un taux de fausse alarme $\overline{\text{Fa/h}} = 1.00$), le fait de calibrer le seuil de décision sur le score de la combinaison des deux branches, montre un déclin de la sensibilité en comparaison de la pipeline P1 à seuil fixe de 0.55 (0.296 contre 0.374).

La Table 10 reporte les performances combinées de la pipeline (P3).

Table 10: Résultats de la somme pondérée *fused* de la pipeline P3.

Pat.	**AUC**	**Sens**	**FA/h**	α
PN00	0.727	0.800	2.10	0.6
PN01	0.587	0.000	0.39	0.6
PN03	0.716	0.000	0.00	0.6
PN05	0.700	0.000	0.00	0.6
PN06	0.503	0.500	0.00	0.6
PN09	0.668	0.000	0.00	0.6
PN10	0.589	0.100	1.83	1.0
PN12	0.593	0.667	1.16	0.6
PN13	0.641	0.000	0.78	0.6
PN14	0.632	0.250	1.57	0.6
PN16	0.763	1.000	0.78	0.6
PN17	0.587	0.500	1.17	0.6
Mn	**0.642**	**0.318**	**0.82**	**0.63**

Dans les résultats finaux de la pipeline, nous obtenons une sensibilité toujours très faible ($Sens = 0.318$) avec $FA/h = 0.82$. Le fait que le taux de faux positifs ai à ce point diminué, nous montre que le modèle discrimine plus que les deux branches individuellement. Cependant, la sensibilité faible nous montre un problème important de contamination d'une branche sur l'autre.

On peut observer que $\alpha = 0.6$ pour tous les patients, sauf PN10, où $\alpha = 1.0$. Cela nous indique que dans le cas de PN10, la branche LightGBM est utilisée à 100% sur tous les folds, certainement à cause de la contrainte d'optimisation $FA/h \leq 2$. Pour les autres patients, avec $\alpha = 0.6$, nous obtenons quelque chose de plus équilibré avec 60% de contribution de LightGBM, et 40% de contribution de MAACD.

Hélàs, comme vu plus haut, la branche MAACD n'est pas du tout discriminante ici, son nombre de faux-positifs élevée nous indique juste que la valeur de MAACD est presque toujours au dessus du seuil calibré sur le train set, faisant gonfler artificiellement le score combinée.

Le problème majeur de cette pipeline, est que le seuil de décision de la branche LightGBM est directement calculée sur la base de ce score artificiellement élevé, faisant monter le seuil à un niveau supérieur et rendant encore plus difficile pour LightGBM de choisir la classe positive.

Nous apprenons alors deux choses de cette pipeline:

1. Le bruit de la branche MAACD est transmis à la branche LightGBM par l'intermédiaire du seuil de décision.
2. Le fait de moyenner les valeurs de MAACD sur toutes les paires apporte une meilleure sensibilité que la baseline, mais aussi plus de bruit.

7.4. P4: OR-Gate Results (Méthode proposée)

Table 11 reporte les résultats du modèle OR-Gate pipeline (P5) à hyperparamètres optimisés

Table 11: OR-Gate results (P5) — `ALARM_CONSEC`= 6, thr= 0.6. Best overall configuration across the hyperparameter grid.

Patient	#Seizures	AUC	Sensitivity	FA/h
PN00	5	0.835	**1.000**	2.27
PN01	2	0.637	**1.000**	1.96
PN03	2	0.871	**1.000**	0.78
PN05	3	0.708	0.667	0.00
PN06	2	0.478	**1.000**	1.17
PN09	3	0.747	0.667	1.08
PN10	10	0.598	0.700	1.73
PN12	3	0.585	**1.000**	1.16
PN13	3	0.657	**1.000**	2.35
PN14	4	0.591	0.500	1.76
PN16	2	0.865	**1.000**	1.17
PN17	2	0.549	**1.000**	0.78
Mean	**43**	**0.677**	**0.878**	**1.35**

(`ALARM_CONSEC` = 6, threshold = 0.6), which achieved the meilleure compromis sensibilité–spécificité trade-off obtenu par grid-search.

La pipeline OR-gate a obtenue une sensibilité moyenne de **0.878** avec un taux de faux-positifs FA/h moyen de **1.35**, une amélioration non-négligeable par rapport à toutes les autres pipeliens. Nous avons améliorer de +11.4% la sensibilité de la baseline, avec surtout une nette amélioration du taux de faux-positifs de −74.6%

Table 12: OR-Gate hyperparameter grid search results.

ALARM_CONSEC	Threshold	AUC	Sensitivity	FA/h
6	**0.6**	**0.677**	**0.878**	**1.35**
6	0.7	0.677	0.842	1.21
6	0.8	0.677	0.825	1.15
7	0.6	0.677	0.854	1.47
7	0.7	0.677	0.826	1.29
7	0.8	0.677	0.818	1.20
8	0.6	0.677	0.850	1.45
8	0.7	0.677	0.822	1.34
8	0.8	0.677	0.793	1.27
10	0.6	0.677	0.833	1.39
10	0.7	0.677	0.789	1.35
10	0.8	0.677	0.785	1.33

Hyperparameter sensitivity

Table 12 présente le grid-search sur `ALARM_CONSEC` $\in \{6, 7, 8, 10\}$ et threshold $\in \{0.6, 0.7, 0.8\}$.

Le score AUC est invariable et indépendant des paramètres choisis (0.677 pour toutes les configurations). Comme prévu, le score AUC dépend seulement de l'ordre de classement et non de la décision de déclencher une alarme. Comme on pouvait s'y attendre, la sensibilité décline progressivement à mesure qu'on augmente le seuil de décision et FA/h diminue à mesure que `ALARM_CONSEC` augmente. La configuration (`ALARM_CONSEC`= 6, thr= 0.6) obtient la meilleure sensibilité (0.878) à un taux FA/h = 1.35. Notons que la configuration (`ALARM_CONSEC`= 6, thr= 0.8) offre un tout aussi bone sensibilité (0.825) avec une légère baisse de faux-positifs (FA/h = 1.15)

7.5. Cross-Pipeline Comparison

Table 13: Performance moyenne sur toutes les pipelines (12 patients, 43 crises). Meilleures valeurs par métriques en gras.

ID	Pipeline	AUC	Sensitivity	FA/h
Baseline	ThAlgo (avec `ALARM_CONSEC`)	0.513	0.764	5.32
P1	LGBM-All	0.679	0.374	1.30
P2	LGBM-NoPLI	0.677	0.432	1.52
P4	Fused (LGBM + MAACD)	0.642	0.318	0.82
P3	**OR-Gate (proposed)**	**0.677**	**0.878**	**1.35**

Table 13 présente les résultats moyens sur la Baseline et les 4 pipelines. La pipeline proposée P4 montre la meilleure sensibilité de loin tout en maintenant un score FA/h acceptable.

Key observations.

1. *Le modèle OR-gate est essentiel.* En remplaçant le OR par une somme pondérée (P4) ou un classifieur LightGBM incluant les features de MAACD (P2) les deux cas ont montré une faible sensiblité à cause du bruit globale de MAACD atténuant plus LightGBM que le complétant.

2. *Les features de connectivité n'aident pas les classifieur généraux comme LightGBM* P2 (no PLI/wPLI) valait autant ou dépassait même P1 sur toutes les métriques. Faisant sens avec la faible importance univariée des familles PLI/wPLI observée dans l'analyse des features 2 La connectivité contribue seulement lorsqu'elle est exploitée de manière sélective par la branche Focal MAACD inspirée de la baseline.

3. *La branche Focal MAACD fournit une couverture informative des crises complémentaire* Pour 6 patients sur 12, P5 a obtenue une sensibilité = 1 quand LightGBM seul, en trouvait une ≤ 0.5 (e.g PN01: 0.00 $\rightarrow$ 1.00; PN03: 0.00 $\rightarrow$ 1.00; PN06: 0.50 $\rightarrow$ 1.00).

Ces patients correspondent aux cas où le changement péri-ictale est concentré sur une seule paire focale wPLI, alors invisible pour le modèle général mutli-feature (LightGBM).

4. *La plus grande limite est FA/h.* Bien que OR-gate ai permit une diminution majeure de FA/h. Un taux FA/h = 1.35 dépasse la cible clinique communement citée FA/h < 0.15 [12] Réduire le taux de fausses alarmes sans sacrifier la sensibilité reste la clé du problème, particulièrement pour le patient PN10 (FA/h = 1.73) et PN13 (FA/h = 2.35).

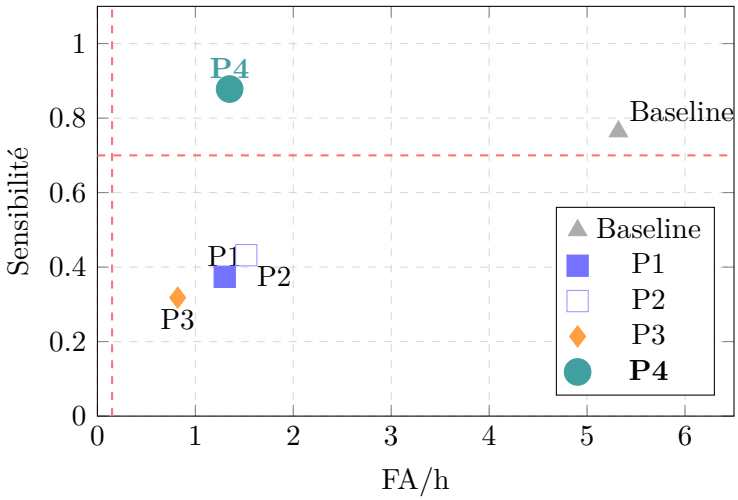

Figure 4: Compromis Sensibilité vs. FA/h. Lignes rouges : cibles cliniques [12].

8. Discussion

Résultats clés. P4 est la seule pipeline dépassant la cible clinique de sensibilité (Sens = 0.878 > 0.70), avec Sens = 1.000 pour 8 patients sur 12. L'élément architectural décisif est le découplage : toute fusion directe (P3) ou inclusion de MAACD en entrée de LightGBM (P1) dégrade les résultats.

Rôle des features de connectivité. PLI, wPLI et MAACD figurent en bas du classement univarié, mais la branche MAACD focale de P4 récupère seule 6 patients que LightGBM manquait (PN01 : 0.00 → 1.00, PN03 : 0.00 → 1.00, PN06 : 0.50 → 1.00). La connectivité est pertinente mais localisée sur 1–2 paires spécifiques.

Gestion du déséquilibre. Traité par pondération ($w^+ = N^-/N^+$) et calibration du seuil per-fold. Malgré cela, certains patients (PN05, PN09) ont Sens = 0 sur P1/P2 – les features spectro-temporelles seules ne capturent pas la transition préictale.

Stabilité et variabilité. AUC entre 0.465 (PN06) et 0.871 (PN03) selon les patients – forte variabilité inter-patients typique des EEG. PN10 (10 crises) est le plus stable grâce au plus grand set d'entraînement.

Limites.

- *Corrélation des fenêtres.* L'overlap de 5/6 s peut légèrement surestimer les performances.
- *Évaluation offline.* Un déploiement temps réel nécessiterait l'évaluation de la latence et de la robustesse aux artefacts.
- *Annotations manuelles.* L'imprécision sur les horodatages peut biaiser les labels préictaux.
- *Dataset monocentrique.* 14 patients, 47 crises – généralisation limitée. Une validation externe (CHB-MIT, TUSZ) est nécessaire.

Pertinence clinique. FA/h = 1.35 est 9 fois au-dessus de la cible clinique (< 0.15). Cependant, Sens = 0.878 (87.8% des crises anticipées) est cliniquement significatif dans un contexte de surveillance hospitalier supervisée.

9. Conclusion

Nous avons présenté une approche multi-paradigme pour la prédiction de crises épileptiques sur SIENA Scalp EEG, comparant cinq pipelines progressives sous protocole LOSO. La pipeline **OR-Gate** (P4) découple les features spectro-temporelles (LightGBM) de la connectivité MAACD (branche focale sur une unique paire wPLI patient-spécifique). Ce découplage est essentiel : toute fusion directe dégrade les performances car le bruit MAACD contamine le classifieur global. La pipeline proposée atteint Sens = **0.878** et FA/h = **1.35**, soit +11.4% de sensibilité et −74.6% de FA/h par rapport à la baseline.

La principale limite reste FA/h = 1.35 (cible < 0.15). Les perspectives futures incluent l'optimisation des seuils adaptatifs, la validation externe sur CHB-MIT ou TUSZ, et l'intégration de réseaux de neurones temporels. Nous pourrions aussi exploiter les canaux ECG inclues dans le signal et tester leur capaciter à ajouter ou non un pouvoir discriminant favorable. Enfin, nous avons au cours de cette étude considéré uniquement deux catégories de labels ictales+pré-ictales ou inter-ictales, nous pourrions envisager comme amélioration un modèle plus précis capable de reconaître de manière distincte ces trois types de phases.

Remerciements

Données issues de la base SIENA Scalp EEG via PhysioNet [4].

Je remercie M. Detti Paolo pour avoir gentillement répondu à mes questions sur leur jeu de donnée ainsi que l'Unité de Neurologie de l'Université de Siena pour la mise à disposition publique de leur données.

Enfin, je remercie M. REDJAL et Mme MSAAD pour leur accompagnement au cours de ce projet

References

[1] World Health Organization, "Epilepsy: a public health imperative," WHO, Geneva, 2019.

[2] A. H. Shoeb, "Application of machine learning to epileptic seizure onset detection and treatment," Ph.D. dissertation, MIT, 2009.

[3] A. Shoeb and J. Guttag, "Application of machine learning to epileptic seizure detection," in *Proc. ICML*, 2010, pp. 975–982.

[4] A. L. Goldberger *et al.*, "PhysioBank, PhysioToolkit, and PhysioNet," *Circulation*, vol. 101, no. 23, pp. e215–e220, 2000.

[5] T. Alotaiby *et al.*, "A review of channel selection algorithms for EEG signal processing," *EURASIP J. Advances Signal Process.*, 2015.

[6] B. Hjorth, "EEG analysis based on time domain properties," *Electroencephalogr. Clin. Neurophysiol.*, vol. 29, pp. 306–310, 1970.

[7] T. Higuchi, "Approach to an irregular time series on the basis of the fractal theory," *Physica D*, vol. 31, pp. 277–283, 1988.

[8] M. Vinck *et al.*, "An improved index of phase-synchronization for electrophysiological data," *NeuroImage*, vol. 55, no. 4, pp. 1548–1565, 2011.

[9] P. Detti, G. Vatti, and G. de Lara Matiasek, "EEG synchronization analysis for seizure prediction," *Processes*, vol. 8, no. 7, p. 846, 2020.

[10] F. Pedregosa *et al.*, "Scikit-learn: machine learning in Python," *JMLR*, vol. 12, pp. 2825–2830, 2011.

[11] A. Gramfort *et al.*, "MEG and EEG data analysis with MNE-Python," *Frontiers in Neuroscience*, vol. 7, p. 267, 2013.

[12] M. Winterhalder *et al.*, "The seizure prediction characteristic," *Epilepsy & Behavior*, vol. 4, no. 3, pp. 318–325, 2003.